


TEDxplore

dai libri alle idee

H2. Evoluzione del Data Warehouse

Gandolfi Leonardo 1086657
Morgera Claudio 1093069
Zambonelli Julia 1093775



Navigazione

Per consentire ai lettori digitali di esplorare nuove idee, argomenti e prospettive differenti.

Per mezzo di **TEDExplore** è possibile consigliare brevi video con un focus diverso dal genere di libri letti dall'utente, che consenta di catturare la loro attenzione

La soluzione: Sfruttare una rete di video correlati in un data warehouse.
Possibile ottimizzando il JobPyspark su AWS glue per elaborare il dataset `related_videos.csv`

Esperienza utente

La nostra interfaccia offre una **navigazione fluida** e a **bassa latenza**.

Grazie allo schema documentale a nido, l'applicazione interroga un singolo record e ottiene istantaneamente la lista completa dei talk correlati

Cosa offriamo: Un'esperienza di “**esplorazione guidata**”.

L'utente non riceve solo una lista passiva ma può visualizzare immediatamente anteprime (titoli e durante dei video consigliati) stimolando la scoperta di nuovi contenuti correlati

Data ingestion



CORE DATASETS

`final_list.csv`
`details.csv`


forniscono l'anagrafica
e i metadati descrittivi
dei talk.



RELATIONSHIPS

`related_videos.csv`

è la base dati
fondamentale per
mappare le relazioni
"watch next".



SEMANTICS

`tags.csv`

permette la
categorizzazione e
l'associazione ai generi
letterari.

• BUCKET S3

Utilizziamo un bucket S3 per archiviare i dati grezzi

[tedx-data-jz](#)

[tedx-log-jz](#)

[tedx-script-jz](#)

Stati Uniti orientali (Virginia settentrionale)
us-east-1

29 Apr 2026 05:52:51 PM CEST

Stati Uniti orientali (Virginia settentrionale)
us-east-1

29 Apr 2026 06:05:30 PM CEST

Stati Uniti orientali (Virginia settentrionale)
us-east-1

29 Apr 2026 06:03:50 PM CEST

tedx-data-jz

Info

Oggetti

Metadati

Proprietà

Autorizzazioni

Parametri

Gestione

File system - nuovo

Punti di accesso

Oggetti (5)

Copia URI S3

Copia URL

Scarica

Apri

Elimina

Operazioni

Crea cartella

Carica

Gli oggetti sono le entità fondamentali archiviate in Amazon S3. Per ottenere un elenco di tutti gli oggetti nel bucket, puoi utilizzare l'inventario di Amazon S3. Per consentire ad altri utenti di accedere ai tuoi oggetti, è necessario concedere loro le autorizzazioni esplicitamente. Ulteriori informazioni

Trova oggetti per prefisso

< 1 >

	Nome	Tipo	Ultima modifica	Dimensioni	Classe di storage
☐	 details.csv	csv	07 May 2026 10:50:27 AM CEST	5.9 MB	Standard
☐	 final_list.csv	csv	07 May 2026 10:50:28 AM CEST	1.6 MB	Standard
☐	 images.csv	csv	07 May 2026 10:50:28 AM CEST	2.4 MB	Standard
☐	 related_videos.csv	csv	07 May 2026 10:50:29 AM CEST	5.0 MB	Standard
☐	 tags.csv	csv	07 May 2026 10:50:30 AM CEST	3.7 MB	Standard

- Job PySpark

Per evitare la duplicazione del codice e rendere l'infrastruttura scalabile, non abbiamo inserito i percorsi dei bucket S3 staticamente nel codice (hardcoded), ma abbiamo sfruttato la funzionalità dei **Job Parameters** di AWS Glue.

Questo approccio permette a diverse utenze di eseguire lo stesso identico script PySpark.

CHIAVE	VALORE
- - DETAILS_PATH	s3: // tedx-data-jz/details.csv
- - FINAL_LIST_PATH	s3: // tedx-data-jz/final_list.csv
- - RELATED_VIDEOS_PATH	s3: // tedx-data-jz/related_videos.csv
- - TAGS_PATH	3: // tedx-data-jz/tags.csv

```
args = getResolvedOptions(sys.argv, [
    'JOB_NAME',
    'FINAL_LIST_PATH',
    'DETAILS_PATH',
    'RELATED_VIDEOS_PATH',
    'TAGS_PATH'
])

##### START JOB CONTEXT AND JOB
sc = SparkContext()
glueContext = GlueContext(sc)
spark = glueContext.spark_session

job = Job(glueContext)
job.init(args['JOB_NAME'], args)

#### FROM FILES
tedx_dataset_path = args['FINAL_LIST_PATH']
details_dataset_path = args['DETAILS_PATH']
tags_dataset_path = args['TAGS_PATH']
related_dataset_path = args['RELATED_VIDEOS_PATH']
```


Logica ETL: "Watch Next"

Il codice dedicato al 'Watch Next' ha l'obiettivo di trasformare una lista piatta di relazioni in una struttura documentale ottimizzata per il NoSQL.

```
# RELATED VIDEOS (WATCH NEXT)
related_dataset = spark.read.option("header", "true").csv(related_dataset_path)

related_dataset_agg = related_dataset.groupBy(col("id").alias("id_related_ref")).agg(
    collect_list(
        struct(
            col("related_id"),
            col("title").alias("related_title"),
            col("slug").alias("related_slug"),
            col("duration").alias("related_duration")
        )
    ).alias("related_videos")
)
```

In questo modo, passiamo da un modello relazionale a un modello documentale



I dati elaborati dal Job PySpark vengono persistiti su **MongoDB Atlas** utilizzando un approccio documentale denormalizzato.

- **Single Record Query:** Tutti i metadati e i talk correlati sono contenuti in un unico documento.
- **Performance:** Eliminazione delle JOIN a runtime per garantire una latenza quasi nulla sul mobile.
- **Schema Nidificato:** related_videos diventa un array di oggetti JSON pronti all'uso.

Criticità

01. Mappatura


Difficoltà nel mappare correttamente le corrispondenze tra colonne di related_videos e i generi letterari

```
final List<Map<String, dynamic>> generiData = [  
    {'nome': 'Mente e Comportamento', 'tagDatabase': ['psychology', 'brain', 'identity'],'percentuale': 0.02, 'colore': Colors.grey },  
    {'nome': 'Scenari globali', 'tagDatabase': ['global issue'],'percentuale': 0.08, 'colore': Colors.grey },  
    {'nome': 'Narrazione', 'tagDatabase': ['humanity', 'identity'],'percentuale': 0.14, 'colore': Colors.grey },  
    {'nome': 'Contenuti multimediali', 'tagDatabase': ['animation', 'media'],'percentuale': 0.01, 'colore': Colors.grey },  
  
    ...  
];
```

02. Struct

Necessità di convertire strutture tabellari in array di oggetti JSON adatti a MongoDB

Possibili evoluzioni



Lambda Function Backend

Implementazione della logica di business serverless per interrogare MongoDB Atlas ed eseguire la funzione `Get_Watch_Next_by_Idx` in modo scalabile.



Secure API Gateway

Esposizione degli endpoint REST protetti per consentire all'app Flutter di consumare i dati in sicurezza, gestendo autenticazione e throttling.